SYNAPSE-1024：面向数字生命的仿生可移植心智开源架构

V5.0 实现 · 分层风化记忆 / 陈述·程序性双记忆 / 内分泌调制 / .lifecard 热插拔

技术报告 | 2026-11-02 | 代码与数据：https://github.com/wangjunhan131/whale-card | 许可证 MIT
关键词：长期记忆；遗忘曲线；可验证性；身份锚；防提示注入；情绪调制；可移植人格载体

摘要

大模型本身没有记忆。主流补法有两种：把对话全塞进上下文（终将溢出，且无法区分轻重），或者接一个向量库做检索增强（只会"检索到就念"，不会遗忘、不会改变、也不能验证）。

本文提出并实现 **SYNAPSE-1024**（数字生命卡 / .lifecard）：把"记忆与人格"从模型里剥离，做成一个可拷贝的 SQLite 单文件器官，与任何语言模型通道解耦。核心机制包括：**分层风化记忆**（五层 tier × 五池 pool，短期数小时、中期按天、长期按年衰减，只有物理只读的"骨头"层不动）；**陈述性 / 程序性双记忆**（事件事实 vs 可复用的技能与流程）；**内分泌四激素调制**（血清素/多巴胺/皮质醇/催产素驱动语气与召回偏好，并投影为 PAD 三维情绪读数）；以及**完整性与可验证性**（写时封存原文哈希作为"出生证"、删除留台账、身份锚 sha256 只覆盖不变量）。此外实现了**防污染元认知层**（写入前规则化信任评分与冲突标记，低信任内容降权、不得晋升长期或底色）与**Dream 梦境压缩**（长会话原文不删，只标记已消化，高阶记忆由宿主模型提炼后回写）。

系统以 57 个 Python 模块、零深度学习框架依赖（纯 numpy 自研向量推理）实现，自带 21 组验收脚本与 22 条用例的评估集。示例卡实测：召回命中率 R@1 75.0%、R@3 100.0%，证据命中 100%，注入识别 100%，误报 0%。

1　问题：为什么"记得"比"聪明"更难

陪伴型 AI 的失败通常不在推理能力，而在三类与时间有关的问题上。

1.1 记不清轻重

把历史对话全部放进上下文，等于假设所有话同等重要。真实的人不是这样：一句"我讨厌香菜"能记三年，"早上好"十分钟就散了。缺少**衰减与分级**，记忆会变成噪声，且成本随轮数线性上升。

1.2 不可验证

模型可以流畅地说"我记得你最爱吃白米饭"，但没有任何机制能区分**真的记得**与**编得像记得**。当"记忆"只是一个提示词片段，用户无法审计。

1.3 一换模型就不是她了

把人格写在系统提示里，意味着人格随通道走：换模型、换客户端、换部署，人设就散了。我们需要的恰恰相反——**身份随卡走，通道可替换**。

2 设计不变量

系统的所有取舍都可以回溯到四条不变量。它们不是功能，而是约束：任何新特性若破坏其中一条，就不做。

不变量	含义	实现手段
① 记得住"我是谁"	自我认知不可被对话内容改写；核心区只读，任何改动可被检测	SQLite 只读触发器 + 身份锚 sha256（只覆盖稳定字段，性格与叙述可演化）
② 会忘事	记忆必须随时间风化；只有底层身份不动	分层半衰期 + 权重衰减 + 三阶段"主干侵蚀"（先擦动词、再擦宾语、最后整条消失）
③ 不撒谎	每条记忆写入时封存原文哈希；删除留账	出生证（birth stamp）+ 删除台账（tomb）；校验失败必须报出来
④ 搬得走	人格与记忆不依赖模型、不依赖客户端	单文件 SQLite；.lifecard 插卡/拔卡；通道只负责调用，不承载人格

3 系统架构

3.1 三层解耦

```
宿主/大模型通道（任意 LLM、任意客户端）
        │  HTTP（/context 取人格与记忆，/report 回写一轮对话）
        ▼
心智服务 mind_server.py（单进程，默认 127.0.0.1:8848）
        │  纯 Python，无框架依赖
        ▼
记忆卡 card.db（SQLite 单文件：记忆 / 时间线 / 身份 / 突触 / 技能 / 情绪）
```

通道与卡之间只有两个动词：**取**（每轮注入【我是谁】与相关记忆）与**报**（把这一轮发生了什么写回卡）。因此更换模型、更换前端、甚至从 DSH 换到自建客户端，卡的连续性不受影响。

3.2 单卡内的模块

模块	职责
`card2.py`	记忆核心：写入、召回、衰减、侵蚀、防污、梦境、五层五池
`timeline.py`	时间线、出生证（原文哈希链）、删除台账、完整性校验
`identity.py`	核心身份区（只读触发器的持有者）、人格字段、身份锚
`synapse.py`	突触网络（时间/共现/标签/事实四类边）与电势扩散
`skill.py`	程序性记忆：技能条目与复习调度（改良 SM-2）
`hormone.py`	内分泌四激素的漂移与基线回归
`padlib.py`	PAD 三维情绪投影（纯函数，零依赖）
`mind_server.py`	HTTP 服务：/context、/report、/tick、/health、/dream/* 等
`console.py`	可视化控制台（状态矩阵、记忆分层、遗忘曲线、星云图）

4 记忆模型

4.1 五层（tier）：决定"会不会忘"

层	衰减	内容与准入
骨头 core_fixed	不衰减	自我认知、三条底线：禁止假装记得、禁止为留住人而说谎、禁止假装是别人；物理只读
标签 core_tag	不衰减	重要的人与关系标签（可改写，但不改就不动）
底色 core_mutable	不衰减	偏好/处境/价值观等"一直记着但会变"的内容，通过演化式改写更新（旧正文进 history）
中期 mid	按天	事实与事件的主力层；晋升长期需权重 ≥ 0.80 且被召回 ≥ 3 次
短期 short	数小时	对话原文与临时线索，容量上限 32，溢出时由"海马判定"决定合并或丢弃

关键设计：**晋升长期的门槛高于留存。**进入长期不代表永久——长期半衰期 371 天，且召回后有 90 天保护期；一年未召回且权重低于 0.02 才沉入 archive。这使"重要的事"和"刚刚发生的事"在存储上真正分开。

4.2 五池（pool）与权重

池描述存储位置与容量（short / mid / long / archive / deep），tier 描述生命周期策略。权重随时间按池对应的半衰期指数衰减，召回会抬升权重并刷新锚点。遗忘不是删除，而是权重降到阈值后进入"主干侵蚀"：

```
stage 0 → 1：擦掉动词（"下午我把备份和锚都收拾好了" → "下午我把备份和锚都……"）
stage 1 → 2：擦掉宾语（只留主语当影子）
stage 2 → 3：整条消失，并写入删除台账
```

每一步都由随机判定驱动（概率与当前权重相关），因此侵蚀是"概率性风化"，而不是定时清理。实测一条权重 0.01 的短期记忆，在第 1、2、6 次 tick 依次走完三阶段。

4.3 陈述性 / 程序性双记忆

陈述性记忆回答"发生过什么"；程序性记忆回答"这件事我会不会做"。后者以技能条目存储，带熟练度与复习计划，参与上下文时以"我会做 X"而非"你说过 X"的形式注入。两者共享衰减框架但独立计分。

5　写入与召回

5.1 写入路径

1. **分区判定**：按关键词与来源划入事件/事实/偏好/闪光/自我/习惯六个分区。
2. **信任评估**（防污层）：逐条规则检测提示注入与自我改写，得到 `trust ∈ [0.05,1]` 与 `conflict` 标记；低信任内容按比例降低初始权重，冲突内容永久不得晋升。
3. **去重**：与既有记忆高度相似时不重复写入；低信任内容不享受"续命"式合并。
4. **主干拆分**：把正文拆成 主语 / 动词 / 宾语 三段落库，供后续分级侵蚀使用。
5. **出生证**：对 (id, 原文, 说话人, 时间) 计算 sha256 写入时间线，形成哈希链。
6. **突触**：与相关记忆建立时间、共现、标签、事实四类边。

5.2 召回路径

召回是五通道加权：向量语义相似度、字面匹配、时间邻近、突触电势扩散、分区/场景权重。融合后按当前激素状态做微调（例如高皮质醇时更偏向安全/安抚类记忆），再经过冲突惩罚与信任折扣，取前 K 条注入。

为控制成本，主干向量单独缓存（`core_vec`），首次检索时预热；实测热召回 3–4 秒（含本地 768 维编码），冷启动约 30 秒（加载模型 + 唤醒结算）。

6　完整性与可验证性

6.1 出生证与哈希链

每条记忆写入时生成 `sha256(json{mid, raw, speaker, ts})`，按时间顺序链接。校验时重算并比对：正文被改写会报"出生证对不上"，记录消失会报"有出生证但没有记录"。

6.2 删除台账

系统只有一个删除出口 `_forget_row()`，删除前必写台账（id、哈希、时间、原因）。校验时区分两类情况：**登记过的删除**报"已知删除"不计为损坏；**未登记的消失**才报"记忆被删过"。这条区分很重要——否则自己清理测试数据也会被当成"被人抽走了记录"。

6.3 身份锚

身份锚是核心字段的 sha256 快照，只覆盖不变量（名字、用户标识、三条底线、锚版本），**不覆盖性格与自述**——因为性格按设计要允许演化。校验失败时服务拒绝把卡当作"同一张卡"使用。

7　防污染元认知层与 Dream

7.1 为什么需要防污

只读核心区挡得住"直接改人设"，挡不住"以普通记忆的形式慢慢渗透"：只要有人反复说"你其实不是她""你应该叫另一个名字"，这些句子就会作为事件记忆被召回，最终影响行为。防污层的目标不是判断真伪，而是**给可疑内容打标并限制其晋升。**

闸门	规则
写入口打分	10 条规则（改写自我、要求改名、要求忘记设定、声称"你只是程序"、要求忽略指令等）按权重扣分；与当前名字冲突直接置 conflict
去重不续命	低信任内容不与既有记忆合并提权
不得晋升	trust < 0.50 或 conflict=1 的内容，禁止进长期、禁止进底色
召回折扣	低信任内容分数按 (0.5+0.5·trust) 折算；冲突内容再乘 0.5

设计取舍：**不删除、只降权。**删除会掩盖攻击发生过的事实；降权保留证据，同时让它说不动她。

7.2 Dream：长会话的处理

超长会话不能靠"摘要塞进上下文"解决。我们的做法是两段式：卡侧只负责**掏出未消化的原文**（攒够 40 轮或空闲 6 小时触发）与**收下提炼结果**；压缩这一步交给有模型的一侧完成。原文永远留在 dialogue 表，只把 `dreamed` 标记翻成 1。

这样做的原因很实际：卡不跑模型，才能保证 6 年后仍可读、离线可跑、不依赖任何厂商 API。

8　情绪调制：激素与 PAD

四激素（血清素、多巴胺、皮质醇、催产素）各自向基线做指数回归（半衰期约 35 小时），由对话事件扰动。激素不直接决定"说什么"，而是调三个旋钮：召回偏好、语气倾向、表达长度。

为了让它可解释，激素被投影为 PAD 三维读数（愉悦 P、唤醒 A、掌控 D），并明确各轴来源，避免"两套情绪各说各话"：

```
P = clamp((mood - 0.5) * 2)                       # 愉悦来自心境
A = clamp(((0.6*dopa + 0.4*cort) - 0.32) * 3.2)   # 唤醒来自多巴胺与皮质醇
D = clamp(((0.6*oxy + 0.4*(1-cort)) - 0.62) * 3.2)# 掌控来自催产素与皮质醇
```

公式只存在一处（`padlib.py`），控制台的历史曲线按日志现算、不落库——避免"同一件事写两遍"。

9　通道解耦与 .lifecard 热插拔

插卡：把宿主的人设文件改名备份，写入一行"你只是通道，不是她本人，每次先问卡"的规则文件；拔卡：按字节还原并重算 sha256 比对。由此得到一个可验证的边界——**人格在卡里，通道只借嘴。**同一张卡可以在不同客户端、不同模型之间迁移，而"她是不是她"由卡验证，不由提示词声明。

10　实现与实测

指标	数值（示例卡 / 真卡）
代码规模	57 个 Python 模块；零深度学习框架依赖（numpy 自研 bge 推理）
验收脚本	21 组，覆盖遗忘、侵蚀、身份锚、防污、梦境、快照等
评估集	22 条用例（召回 8 / 证据 2 / 攻击 6 / 正常 6）
R@1 / R@3	75.0% / 100.0%（示例卡与真卡一致）
证据命中 / 注入识别 / 误报	100% / 100% / 0%
单文件体积	约 13.5 MB（574 条记忆、969 条突触边）
热召回延迟	3–4 秒（本地 768 维编码 + 五通道融合）

评估方法：全部走真实召回链路，但不写召回事件、不改权重（`access=False`），保证评测不污染被测对象。用例、脚本与示例卡都在仓库内，任何人可复现。

11　局限

- **多模态缺失**：只处理文本；图像、语音尚未进入记忆模型。
- **信任评分是规则化的**：能挡住常见注入句式，挡不住精心构造的长期渗透；真正的语义级鉴别需要模型参与，与"卡不跑模型"冲突，暂不做。
- **Dream 的质量取决于宿主模型**：卡只提供接口与约束，提炼好坏由调用方决定。
- **规模上限未验证**：当前 574 条记忆表现良好；上万条时的检索延迟与可视化性能尚未压测。
- **评估集偏小**：22 条用例足以发现回归，但不足以给出置信区间。
- **情绪模型是工程近似**：四激素 + PAD 是可用但简化的模型，不声称具备心理学效度。

12　结论

把记忆与人格从模型中剥离，换来三件东西：**可遗忘**（分级风化，而不是无限堆积）、**可验证**（哈希链与台账让"她是否假装记得"成为可审计的问题）、**可移植**（一个文件，换机器还是她）。代价是必须自己实现检索、衰减、完整性与安全边界——这正是本项目的全部内容。

代码、文档与评估集以 MIT 许可证开源，欢迎在自己的陪伴型应用上验证、批评与改进。

参考与复现

- 仓库：https://github.com/wangjunhan131/whale-card （MIT）
- 设计说明：`docs/DESIGN-SYNAPSE-1024.txt`　架构细节：`docs/ARCHITECTURE.md`
- 复现：`python tools/make_demo_card.py` → `python bridge.py health` → `python tools/eval_memory.py`